

Sistema de prevención de fraude

Data Scientist Technical Challenge 2026

Scoring, calibración, decisión económica y camino a producción

ROC AUC TEST

0,8550

ranking fuera de muestra

PR AUC TEST

0,3761

prevalencia: 4,27%

UPLIFT TEST

+15,9%

vs. aprobar todo

Resultados de la corrida final del 5 de octubre de 2026 sobre 150.000 transacciones.

Autor: Jeison Alarcon

Documento actualizado a partir de los notebooks finales y los artefactos promovidos.

1. Resumen ejecutivo

Qué se construyó, qué evidencia existe y qué falta cerrar.

El challenge busca decidir qué compras aprobar, rechazar o derivar a control cuando la clase fraudulenta es minoritaria y cada error tiene un costo económico distinto. La solución implementa una cadena reproducible: EDA y contrato de datos, features versionadas, entrenamiento de candidatos, calibración de probabilidades, umbral económico y scoring compatible con ONNX.

La corrida final compara 10 familias de modelos. Se promovió **Gradient Boosting** por compatibilidad con la cadena de exportación y serving ONNX; **HistGradientBoosting** obtuvo el mayor PR AUC en VALID. La selección de modelo y la selección del umbral se reportan por separado para evitar confundir ranking predictivo con utilidad económica.

UMBRAL	GANANCIA TEST	ECE TEST
0,272647	221.724,92	0,0135
seleccionado en VALID	unidades monetarias	calibración agregada

Respuesta compacta al enunciado

Punto	Resultado	Estado
1. Ganancia	La política económica mejora TEST en 30.477,70 unidades (+15,9%) frente a aprobar todo.	Demostrado fuera de muestra
2. Informe	EDA, ETL, features, modelos, evaluación, calibración y conclusión están documentados en este informe.	Cubierto
3. Lab vs. producción	Split temporal, contrato, paridad ONNX, shadow, canary y monitoreo propuestos.	Plan de validación
4. Caída en producción	Causas separadas en datos, negocio, modelo y plataforma, con secuencia de diagnóstico.	Cubierto
5. Producción	Empaquetado, staging, rollout gradual, rollback y monitoreo económico.	Diseñado; falta ejecutar

2. Datos y ETL

La partición temporal intenta representar el cambio real del comportamiento de fraude.

El EDA trabaja con 150.000 registros, 19 columnas originales más el target, fechas entre 2020-03-08 y 2020-04-21, cero duplicados exactos y contrato de datos válido. La prevalencia baja de 5,22% en VALID a 4,27% en TEST; por eso la evaluación prioriza PR AUC, calibración y ganancia por monto.

1. Ingesta y calidad: lectura del CSV, tipos, rangos, nulos, duplicados, hash y manifest.
2. Preparación: coerción de tipos, orden por fecha y split fila a fila con TRAIN, VALID y TEST.
3. Feature cache: imputación, encoders, escalado y variables derivadas ajustados únicamente con TRAIN.
4. Entrenamiento: matrices y metadatos versionados para reproducir las 10 corridas.
5. Promoción: Platt scaling, umbral económico en VALID, exportación ONNX y pruebas de paridad.

Partición temporal

Split	Registros	Fraude	Ventana
TRAIN	97.243	5,16%	hasta 2020-04-07
VALID	23.771	5,22%	2020-04-07 a 2020-04-14
TEST	28.986	4,27%	2020-04-14 a 2020-04-21
TOTAL	150.000	-	2020-03-08 a 2020-04-21

CALENDARIO Y VENTANAS DEL SPLIT

La tabla usa el split fila a fila; el gráfico muestra la cobertura diaria.




Figura 1. Volumen diario y prevalencia diaria con las ventanas de VALID y TEST resaltadas.

3. EDA y decisiones de features

La transformación conserva señal útil y hace explícitos los riesgos de disponibilidad.

Las variables categóricas y los faltantes se tratan dentro del pipeline. **o** concentra 72,57% de valores faltantes; **b** y **c**, 8,66%. Se agregan indicadores de missingness cuando la ausencia puede tener señal. **j** tiene 8.324 categorías y usa target encoding OOF. **g** usa categorías raras y one-hot.

Grupo	Transformación	Control
Numéricas	Imputación, clipping de cuantiles y robust scaling.	Indicadores de ausencia
Monto	log1p + robust scaling.	Se conserva para la política económica
Categorías	Rare category, one-hot y target encoding OOF.	Sin target leakage directo
Fecha	Hora, día, fin de semana y codificaciones cíclicas.	Derivadas antes del modelo
k	Se trata como continua en [0,1].	PR AUC univariado 0,0503; PSI 0,0003
score	Se incluye como numérica.	Debe estar disponible antes de decidir




Figura 2. Señal univariada: score destaca y requiere auditoría de disponibilidad pre-decisión.




Figura 3. Importancia relativa: score y o concentran señal en Gradient Boosting; la interpretación no reemplaza la auditoría de leakage.

4. Modelos y comparación

PR AUC es la métrica principal de comparación porque el fraude representa cerca del 5% de las operaciones.

Modelo	PR AUC VALID	ROC AUC VALID	Lectura
HistGradientBoosting	0,4335	0,8683	mejor PR AUC
Stacking ensemble	0,4310	0,8691	segundo PR AUC
Gradient Boosting	0,4286	0,8693	promovido por ONNX
FT-Transformer	0,4284	0,8742	mejor ROC AUC
DCN-V2	0,4282	0,8617	candidato
MLP	0,4191	0,8528	candidato
CatBoost	0,4174	0,8682	candidato
Voting ensemble	0,4146	0,8619	candidato
Regresión logística	0,2044	0,7498	baseline lineal
Dummy	0,0522	0,5000	baseline aleatoria

HistGradientBoosting lidera VALID con PR AUC 0,4335. Stacking queda en 0,4310 y Gradient Boosting en 0,4286. La diferencia entre Gradient Boosting y el líder es 0,0049 puntos de PR AUC; la promoción fue una decisión de despliegue y compatibilidad, no una afirmación de liderazgo predictivo.




Figura 4. Curvas Precision-Recall y ROC en VALID: los candidatos supervisados se separan claramente del dummy.

5. Evaluación fuera de muestra y calibración

TEST se consulta una vez para medir generalización con el umbral ya congelado.

ROC AUC 0,8550 ordenamiento	PR AUC 0,3761 clase positiva	GINI 0,7099 $2 \times \text{ROC AUC} - 1$	KS 0,5583 separación
--	---	--	-----------------------------------

Métrica TEST	Resultado	Lectura
ROC AUC	0,8550	Ordenamiento fuerte; no es accuracy
PR AUC	0,3761	Muy por encima de la prevalencia 0,0427
Gini	0,7099	Consistente con ROC AUC
KS	0,5583	Separación útil de distribuciones
Log loss	0,1340	Calidad probabilística
Brier	0,0343	Error probabilístico bajo
ECE	0,0135	Buena calibración agregada

Capacidad de priorización en TEST

Top-k	Precisión	Recall	Lift
0,5%	82,07%	9,61%	19,22x
1%	72,76%	17,04%	17,04x
2%	57,41%	26,90%	13,44x
5%	35,68%	41,76%	8,35x
10%	24,42%	57,19%	5,72x

Calibración

Platt scaling transforma el score del modelo base en una probabilidad calibrada. En VALID, Brier baja de 0.1102 a 0.0399 y ECE de 0.1928 a 0.0130. En TEST, ECE queda en 0.0135. La última banda de confiabilidad sigue necesitando monitoreo porque concentra pocos casos y una frecuencia observada elevada.




Figura 5. Reliability diagram en VALID antes y después de la calibración de Platt.

6. Política económica y umbral operativo

La política se selecciona en VALID y se mide en TEST sin reoptimizar.

Si M es el monto y p la probabilidad calibrada de fraude, aprobar una operación legítima aporta $0,25M$ y aprobar un fraude resta $1,00M$. Por eso la frontera teórica de punto de equilibrio es $p < 0,20$.

EV(aprobar) = $M \times [0,25 \times (1 - p) - 1,00 \times p]$
EV(aprobar) = $M \times (0,25 - 1,25p)$
Frontera teórica: aprobar si $p < 0,20$

La búsqueda empírica usa los montos reales y las probabilidades calibradas. Selecciona threshold = **0,272647** en VALID, y después lo congela.

Indicador	VALID	TEST
Ganancia del modelo	168.268,79	221.724,92
Aprobar todo	127.601,72	191.247,22
Uplift	+40.667,07 (+31,9%)	+30.477,70 (+15,9%)
Tasa aprobada	94,2%	94,6%
Monto fraudulento aprobado	31.839,41	44.210,77

En TEST se aprueba 94,62% de las operaciones y queda aprobado un monto fraudulento de 44.210,77, frente a 93.580,06 al aprobar todo: una reducción aproximada de 52,8% de la exposición fraudulenta observada.




Figura 6. La curva económica alcanza su máximo empírico en VALID cerca de 0,272647; la línea gris marca 0,20.

7. Cómo acercar laboratorio y producción

La similitud de performance depende de conservar el contrato, la disponibilidad y la cadena de cálculo.

Control	Qué validar	Evidencia
Ventanas temporales	Backtesting con varias ventanas y segmentos de negocio.	PR AUC, ECE y ganancia por ventana
Disponibilidad	Demostrar que score y cada feature existen antes de la decisión.	Auditoría de timestamps y lineage
Paridad	Comparar Python, ONNX, calibrador y contrato en un golden set.	Diferencia máxima de score y decisión
Rendimiento	p50, p95, p99, throughput, timeout y fallback con carga realista.	Reporte de carga del servicio
Shadow / canary	Observar tráfico real sin impacto y liberar gradualmente.	Criterios de go/no-go y rollback
Monitoreo	Schema, missing, categorías, drift, prevalencia, ECE y economía.	Alertas con owner y runbook

El split temporal de 7 días es una buena primera defensa contra leakage temporal, pero no prueba estabilidad durante varias semanas. La paridad ONNX está implementada en la promoción; la latencia debe medirse con el servicio completo y carga representativa, no sólo con una muestra puntual.

Causas probables de una caída

Capa	Causas probables
Datos	Drift de monto, país, dispositivo o comercio; missing, categorías nuevas y eventos atrasados.
Negocio	Cambio de prevalencia, políticas, productos, usuarios, checkout o geografía.
Modelo	Concept drift, leakage, calibración degradada, threshold desactualizado o labels tardías.
Plataforma	Timeout, fallback, orden de columnas, preprocessing distinto, defaults o latencia.

Diagnóstico recomendado

1. Comparar schema, missingness, cardinalidad, prevalencia y distribución de scores offline versus online.
2. Recalcular ROC AUC y PR AUC con labels maduras; separar ranking, calibración y decisión económica.
3. Comparar scores Python y ONNX en el conjunto dorado y revisar fallbacks.
4. Cambiar threshold sólo si el ranking permanece estable y el cambio de prevalencia explica la pérdida.

8. Camino de despliegue

La promoción técnica está preparada; la activación productiva requiere evidencia operativa.

Fase	Pasos	Salida esperada
Cerrar evidencia	Regenerar model card, auditar score y métricas por segmento.	Narrativa alineada con run_id
Empaquetar	Modelo, preprocessor, calibrador, threshold, schema, dependencias y hashes.	Bundle reproducible
Validar	Tipos, nulos, categorías, paridad, latencia y carga.	Golden set y p50/p95/p99
Staging	Shadow, timeouts, faltantes y fallas de features.	Comparación con la versión anterior
Canary	Porcentaje pequeño, criterios de go/no-go y rollback.	Liberación gradual
Operar	Drift, ECE, rechazo, monto fraudulento, ganancia, errores y labels maduras.	Alertas y runbook

Contrato de serving

El scorer recibe las columnas crudas, valida tipos y nulos, aplica el preprocesador versionado, ejecuta el modelo ONNX y el calibrador, y devuelve probabilidad, decisión, threshold aplicado y latencia. La configuración promovida usa feature version v1, hyperparameters v2, seed 42 y calibración Platt.

Antes de producción quedan cinco controles concretos: backtesting en múltiples ventanas; disponibilidad pre-decisión de score; golden set Python <-> ONNX; medición de carga del servicio completo; y monitoreo económico con rollback.

Reproducción

```
poetry run fraud-promote-winner --runs-dir artifacts/runs --config configs/promotion/v1.yml
```

9. Conclusión

Una solución predictiva útil sólo cuando ranking, calibración, economía y operación se leen juntos.

SEÑAL 0,8550 ROC AUC TEST	CALIBRACIÓN 0,0135 ECE TEST	ECONOMÍA +15,9% uplift TEST
--	--	--

- 1. El modelo aprende señal.** El dummy tiene ROC AUC 0,5000; los candidatos supervisados se ubican alrededor de 0,86-0,87 en VALID y Gradient Boosting conserva ROC AUC 0,8550 en TEST.
- 2. La calibración habilita la política.** Platt scaling reduce Brier de 0.1102 a 0.0399 y ECE de 0.1928 a 0.0130 en VALID. La probabilidad calibrada permite buscar un threshold económico interpretable.
- 3. La política mejora la ganancia.** El threshold 0,272647, elegido en VALID y congelado antes de TEST, sube la ganancia de TEST de 191.247,22 a 221.724,92 unidades monetarias.
- 4. Producción requiere más evidencia.** El proyecto está listo para presentarse como solución técnica reproducible. La preparación productiva depende de resolver score pre-decisión, múltiples ventanas temporales, carga del servicio, monitorización y rollback.

Trazabilidad de la corrida

Elemento	Valor
Run promovido	gradient_boosting-v1-v2-v1-seed42-20261005T030618-e4fb98c9
Feature version	v1
Model version	v1
Hyperparameters	v2
Seed	42
Git SHA	a6c5ff26a8069dee147d07e8d46df2cdf0d248d6
Generado	2026-10-05T03:41:42.888111Z

Fuentes primarias: notebooks/02_eda_fraude_ordenado.ipynb, notebooks/02_orquestar_entrenamiento.ipynb, artifacts/promoted/gradient_boosting-v1-v2-v1-seed42-20261005T030618-e4fb98c9/, data/processed/manifest.json y configs/. Los artefactos anteriores se conservan como históricos y no se mezclan con esta corrida final.